Chap 5 策略优化

2022年1月28日 17:05

- 策略优化
 - 构造一个 带可学习参数 θ 的 策略概率函数
 - 两种: softmax 或 高斯法 等
 - Softmax
 - 高斯法,就是假设 policy 是 正态分布的,期望,是 状态 的线性和 (θ 就是权重),方差 可以是固定的,亦可以作为参数的一部分
 - 目标是收获的收益最大
 - 不可微分的,一般是黑箱的 函数
 - 注意,这里的目标函数 J(θ)一般是通过 实际在环境中跑一圈 (或蒙特卡洛法)得到,与可微分法 是不同的
 - □ cross-entropy 方法
 - ◆ 查看 my_learning_agent.py

Derivative-free Method: Cross-Entropy Method

- **2** Treat $J(\theta)$ as a black box score function (not differentiable)

Algorithm 1 CEM for black-box function optimization

```
1: for iter i=1 to N do
2: \mathcal{C}=\{\}
3: for parameter set e=1 to N do
4: sample \theta^{(e)} \sim P_{\mu^{(i)}}(\theta)
5: execute roll-outs under \theta^{(e)} to evaluate J(\theta^{(e)})
6: store (\theta^e, J(\theta^{(e)})) in \mathcal{C}
7: end for
8: \mu^{(i+1)} = \arg\max_{\mu} \sum_{k \in \hat{\mathcal{C}}} \log P_{\mu}(\theta^{(k)})
where \hat{\mathcal{C}} are the top 10% of \mathcal{C} ranked by J(\theta^{(e)})
```

- Sexample of CEM for a simple RL problem: https://github.com/cuhkrlcourse/RLexample/blob/master/my_learning_agent.py
- □ 梯度估计 Finite Difference
 - ◆ Theta 的 每个分量 分别 加一个 极小值,来估计 微商
- 可微分的 (理论模型)
 - □ 一步收益 per-step 的

$$J(\theta) = \mathbb{E}_{\pi_{\theta}}[r]$$

$$= \sum_{s \in \mathcal{S}} d(s) \sum_{a \in \mathcal{A}} \pi_{\theta}(s, a) r$$

- ◆ d 是以 状态 的分布概率, 理论上 应该是用马尔科夫链来计算出来的
- □ 路径收益

Policy Gradient for Multi-step MDPs

- ① Denote a state-action trajectory from one episode as $\tau = (s_0, a_0, r_1, ...s_{T-1}, a_{T-1}, r_T, s_T) \sim (\pi_\theta, P(s_{t+1}|s_t, a_t))$
- ② Denote $R(\tau) = \sum_{t=0}^{T-1} R(s_t, a_t)$ as the sum of rewards over a trajectory τ
- 3 The policy objective is

$$J(heta) = \mathbb{E}_{\pi_{ heta}} \Big[\sum_{t=0}^{T-1} R(s_t, a_t) \Big] = \sum_{ au} P(au; heta) R(au)$$

where $P(\tau;\theta) = \mu(s_0) \prod_{t=0}^{T-1} \pi_{\theta}(a_t|s_t) p(s_{t+1}|s_t,a_t)$ denotes the probability over trajectories when executing the policy π_{θ}

4 Then our goal is to find the policy parameter θ

$$\theta^* = \argmax_{\theta} J(\theta) = \argmax_{\theta} \sum_{\theta} P(\tau; \theta) R(\tau)$$

- τ 理论上 指的是 所有可能的路径中的一个, μ(s0) 指的是以s0作为初始状态的概率, 最终 J(θ) 理论上是在所有可能的路径下 收益的 期望
- ◆ 当然, 理论 是 不可能的, 所以通过 采样来实现
- 。 计算技巧
 - Likelihood ratio: 乘一个,除一个,转化为log的 梯度 Likelihood ratios exploit the following tricks

$$abla_{ heta}\pi_{ heta}(s, a) = \pi_{ heta}(s, a) rac{
abla_{ heta}\pi_{ heta}(s, a)}{\pi_{ heta}(s, a)}$$

$$= \pi_{ heta}(s, a) \nabla_{ heta} \log \pi_{ heta}(s, a)$$

■ 首先, J的梯度, 主要 就是 P 的梯度

$$\nabla_{\theta} J(\theta) = \nabla_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau)$$

$$= \sum_{\tau} \nabla_{\theta} P(\tau; \theta) R(\tau)$$

$$= \sum_{\tau} \frac{P(\tau; \theta)}{P(\tau; \theta)} \nabla_{\theta} P(\tau; \theta) R(\tau)$$

$$= \sum_{\tau} P(\tau; \theta) R(\tau) \frac{\nabla_{\theta} P(\tau; \theta)}{P(\tau; \theta)}$$

$$= \sum_{\tau} P(\tau; \theta) R(\tau) \nabla_{\theta} \log P(\tau; \theta)$$

■ P的梯度,通过 likelihood ratio 等于 policy 的 梯度,直接摆脱了 难算的 MDP 动态转移概率

$$\nabla_{\theta} \log P(\tau; \theta) = \nabla_{\theta} \log \left[\mu(s_0) \prod_{t=0}^{T-1} \pi_{\theta}(a_t | s_t) p(s_{t+1} | s_t, a_t) \right]$$

$$= \nabla_{\theta} \left[\log \mu(s_0) + \sum_{t=0}^{T-1} \log \pi_{\theta}(a_t | s_t) + \log p(s_{t+1} | s_t, a_t) \right]$$

$$= \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t)$$

- 策略优化 policy gradient
 - 理解:本质上是 类似于 加权的 极大似然估计 (但不是)
 - 首先会有一个 初始的 θ 参数,有一个基于 θ 的策略概率分布,
 - 但初始, 策略概率 最大的 不一定是 受益最大的
 - Policy gradient 和 极大似然估计 一样都是样本理论概率的求和, 但 policy gradient 由于 每一种 路径 都乘了 收益,因此 是按照收益加权平均,(即对概率分布进行了一定的扭曲变换)
 - 一次迭代后, 策略分布 会更靠近 收益大的 区域


Understanding Score Function Gradient Estimator

1 Consider the generic form of $E_{\tau \sim \pi_{\theta}}[R(\tau)]$ as

$$\nabla_{\theta} \mathbb{E}_{p(x;\theta)}[f(x)] = \mathbb{E}_{p(x;\theta)}[f(x)\nabla_{\theta}\log p(x;\theta)]$$

$$\approx \frac{1}{S} \sum_{s=1}^{S} f(x_s)\nabla_{\theta}\log p(x_s;\theta), \text{ where } x_s \sim p(x;\theta)$$

- \bullet compute the gradient of an expectation of a function f(x)
- 2 The above gradient can be understood as:
 - ① Shift the distribution p through its parameter θ to let its future samples x achieve higher scores as judged by f(x)
 - 2 The direction of $f(x)\nabla_{\theta} \log p(x;\theta)$ pushes up the log likelihood of the sample, in proportion to how good it is



- 证明参考: https://danieltakeshi.github.io/2017/03/28/going-deeper-into-reinforcement-learning-fundamentals-of-policy-gradients/
 - 第一步构造 J(θ)
 - The policy objective is

$$J(\theta) = \mathbb{E}_{\pi_{\theta}} \left[\sum_{t=0}^{T-1} R(s_t, a_t) \right] = \sum_{\tau} P(\tau; \theta) R(\tau)$$

where $P(\tau;\theta) = \mu(s_0) \prod_{t=0}^{T-1} \pi_{\theta}(a_t|s_t) p(s_{t+1}|s_t,a_t)$ denotes the probability over trajectories when executing the policy π_{θ}

- \circ 求梯度,likelihood ratio,将 $J(\theta)$ 化简为只与 策略概率函数、reward 相关
- 引入 时序因果关系 causality
- 引入 baseline
- actor-critic
- 实际实现中, Gt 的 期望 是 Q(s,a), baseline 的期望是 V(s), 因此可以写成:
 - 1 Advantage function: combine Q with baseline V

$$A^{\pi}(s,a) = Q^{\pi}(s,a) - V^{\pi}(s)$$

2 Then the policy gradient becomes:

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(s, a) A^{\pi_{\theta}}(s, a)]$$

$$abla_{ heta}J(heta) = \mathbb{E}_{\pi_{ heta}}[
abla_{ heta}\log\pi_{ heta}(s,a)A^{\pi_{ heta}}(s,a)]
abla^{\pi}(s,a) = Q^{\pi}(s,a) - V^{\pi}(s)$$

1 Two function approximators contain two sets of parameter vectors,

$$V_{\mathbf{v}}(s) pprox V^{\pi}(s)$$
 $Q_{\mathbf{w}}(s,a) pprox Q^{\pi}(s,a)$